




ANALISIS KUALITAS UDARA DAN PENGEMBANGAN WEBSITE INFORMASI & SOLUSI PENGENDALIAN POLUSI: STUDI KASUS DKI JAKARTA PADA TAHUN 2019 - 2021

Capstone Digital Product Kelompok 5

OUR TEAM



Lidia Aprilia Putri
(2209116041)

as Project Manager



Bertha Joy Rodo Saragi
(2209116047)

as Data Analyst



Rizani Rupa' Madaun
(2209116039)

as Web Developer



PENGGALIAN DATA DAN ANALITIKA BISNIS (DATA MINING)

BUSINESS UNDERSTANDING

Proyek "Analisis Kualitas Udara dan Solusi Pengendalian Polusi: Studi Kasus DKI Jakarta pada Tahun 2019 - 2021" bertujuan untuk mengatasi masalah polusi udara di Jakarta dengan menggunakan dataset "Air Quality Index in Jakarta (2010 - 2021)". Melalui analisis data eksploratif, faktor-faktor dan parameter yang memengaruhi polusi udara diidentifikasi, memungkinkan pembangunan model klasterisasi untuk menganalisis kualitas udara.

Proses dimulai dengan pengumpulan dan persiapan data, diikuti oleh analisis data eksploratif untuk memahami karakteristik dataset serta faktor-faktor kunci yang mempengaruhi polusi udara. Selanjutnya, model klasterisasi dikembangkan dan dilatih menggunakan teknik data mining untuk mengklasifikasikan tingkat polusi udara yang berbeda. Evaluasi model dilakukan untuk memastikan kinerja yang optimal, dengan penyesuaian yang diperlukan untuk meningkatkan akurasi dan kehandalan model. Tujuan akhirnya adalah memberikan wawasan dan rekomendasi untuk manajemen kualitas udara yang lebih baik di Jakarta.

DATA UNDERSTANDING

1. Collect Initial Data

3. Exploration Data Analysis

2. Describe Data

DATA UNDERSTANDING

1. Collect Initial Data

Dataset yang berjudul "Air Quality Index in Jakarta (2010 - 2021)" bersumber dari Kaggle. Dataset ini berisi Air Pollutant Standard Index (AQI) atau Indeks Standar Pencemar Udara (ISPU) yang diukur dari 5 stasiun pemantau kualitas udara (SPKU) di DKI Jakarta sejak tahun 2010 sampai dengan tahun 2021. Dikutip dari Kaggle, data ini diambil dari Dinas Lingkungan Hidup Provinsi DKI Jakarta.

Berikut adalah link Dataset dari Kaggle:

<https://www.kaggle.com/datasets/senadu34/air-quality-index-in-jakarta-2010-2021/data>

DATA UNDERSTANDING

2. Describe Data

- Informasi Dasar

```
df.shape
```

```
(21915, 11)
```

Pada dataset "Air Quality Index in Jakarta (2010 - 2021)" terdapat 21,915 baris, dan 11 kolom. Hal ini menunjukkan bahwa setiap baris mewakili satu tanggal/periode pengamatan kualitas udara dan setiap kolom memberikan informasi tentang berbagai variabel yang berkaitan dengan pengamatan kualitas udara.

DATA UNDERSTANDING

2. Describe Data

- Informasi Lanjutan

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21915 entries, 0 to 21914
Data columns (total 11 columns):
 #   Column      Non-Null Count  Dtype  
---  -
 0   tanggal    21915 non-null  object 
 1   stasiun    21915 non-null  object 
 2   pm10       18778 non-null  float64
 3   so2        18968 non-null  float64
 4   co         19144 non-null  float64
 5   o3         18890 non-null  float64
 6   no2        19009 non-null  float64
 7   max        21886 non-null  float64
 8   critical   19536 non-null  object 
 9   kategori   21915 non-null  object 
10  pm25       1725 non-null   float64
dtypes: float64(7), object(4)
memory usage: 1.8+ MB
```

Berikut adalah penjelasan mengenai masing-masing dari 11 kolom dalam dataset "Air Quality Index in Jakarta (2010 - 2021)":

- tanggal: Kolom ini berisi tanggal pengukuran kualitas udara di stasiun pengukuran.
- stasiun: Kolom ini berisi nama/lokasi pengukuran kualitas udara.
- pm10: Kolom ini berisi partikulat materi dengan diameter < 10 mikrometer, salah satu parameter polusi yang diukur dalam pengukuran kualitas udara.
- so2: Kolom ini berisi kadar sulfur dioksida (SO₂), salah satu parameter polusi yang diukur dalam pengukuran kualitas udara.
- co: Kolom ini berisi kadar karbon dioksida (CO), salah satu parameter polusi yang diukur dalam pengukuran kualitas udara.
- o3: Kolom ini berisi kadar ozon (O₃), salah satu parameter yang diukur dalam pengukuran kualitas udara.
- no2: Kolom ini berisi kadar nitrogen dioksida (NO₂), salah satu parameter polusi yang diukur dalam pengukuran kualitas udara.
- max: Kolom ini berisi nilai tertinggi di antara semua parameter dalam pengukuran kualitas udara.
- critical: Kolom ini berisi nama parameter yang memiliki nilai tertinggi di antara semua parameter dalam pengukuran kualitas udara.
- kategori: Kolom ini berisi kategori kualitas udara berdasarkan Indeks Standar Polusi Udara dalam pengukuran kualitas udara.
- pm25: Kolom ini berisi partikulat materi dengan diameter < 2.5 mikrometer, salah satu parameter polusi yang diukur dalam pengukuran kualitas udara.

DATA UNDERSTANDING

2. Describe Data

- Informasi Statistik Deskriptif

```
df.describe()
```


	pm10	so2	co	o3	no2	max	pm25
count	18778.000000	18968.000000	19144.000000	18890.000000	19009.000000	21886.000000	1725.000000
mean	53.113963	18.117566	20.938048	64.976601	12.364880	66.067623	78.055652
std	18.924586	12.681040	12.473721	36.929404	8.675225	38.578203	23.002984
min	2.000000	0.000000	0.000000	3.000000	0.000000	0.000000	13.000000
25%	41.000000	9.000000	12.000000	39.000000	7.000000	47.000000	63.000000
50%	55.000000	16.000000	18.000000	60.000000	11.000000	66.000000	78.000000
75%	65.000000	25.000000	27.000000	83.000000	15.000000	85.000000	92.000000
max	179.000000	112.000000	135.000000	314.000000	148.000000	314.000000	174.000000

Output diatas merupakan informasi statistika deskriptif untuk setiap kolom numerik dalam dataset "Air Quality Index in Jakarta (2010 - 2021)".

DATA UNDERSTANDING

3. Exploration Data Analysis

- Distribution




Visualisasi histogram distribusi/penyebaran kategori kualitas udara dalam dataset "Air Quality Index in Jakarta (2010 - 2021)" menunjukkan frekuensi masing-masing kategori kualitas udara di Jakarta selama periode tersebut. Setiap batang pada histogram mewakili frekuensi masing-masing kategori kualitas udara. Histogram memiliki sumbu-x yang menunjukkan kategori kualitas udara dan sumbu-y yang menunjukkan jumlah frekuensi setiap kategori. Dari visualisasi ini, dapat dilihat bahwa kategori "Sedang" memiliki frekuensi tertinggi atau terbanyak yaitu 13.042, diikuti oleh kategori lainnya. Ini menunjukkan bahwa sebagian besar waktu selama periode tersebut, kualitas udara di Jakarta dapat dikategorikan sebagai "Sedang".

DATA UNDERSTANDING

3. Exploration Data Analysis

- Relationship




Visualisasi heatmap relationship atau korelasi antara polutan dan nilai maksimal dalam dataset "Air Quality Index in Jakarta (2010 - 2021)" adalah cara yang efektif untuk memperlihatkan seberapa erat hubungan antara masing-masing polutan dan juga dengan nilai maksimal. Warna setiap sel menunjukkan tingkat korelasi dan arah korelasi antar variabel. Semakin biru (gelap) warna selnya, maka semakin rendah tingkat korelasinya. Sebaliknya, semakin merah (gelap) warna selnya, maka semakin tinggi tingkat korelasinya. Korelasi antara PM2.5 dan nilai maksimal (Max) adalah 0.96, yang menunjukkan hubungan yang sangat kuat. Ini berarti konsentrasi PM2.5 menjadi konsentrasi dengan perhitungan tertinggi (max) pada suatu waktu.

DATA UNDERSTANDING

3. Exploration Data Analysis

- Composition

Persentase Kategori Kualitas Udara




Visualisasi Pie Chart untuk kategori kualitas udara dalam dataset "Air Quality Index in Jakarta (2010 - 2021)" menunjukkan proporsi persentase masing-masing kategori. Kategori "sedang" memiliki proporsi terbesar dalam kualitas udara Jakarta dengan persentase sebesar 59,5%. Ini menunjukkan bahwa kualitas udara yang dimonitor berada dalam kategori sedang lebih dari setengah dari total waktu pengamatan.

DATA UNDERSTANDING

3. Exploration Data Analysis

- Comparison



Visualisasi stacked barplot ini bertujuan untuk menyoroti jumlah kritis/polutan terbanyak dalam setiap stasiun dalam dataset "Air Quality Index in Jakarta (2010 - 2021)". Tinggi Stack Bar mewakili jumlah total kritis/polutan yang terukur di setiap stasiun. Bagian dari Setiap Stack mewakili kontribusi masing-masing polutan (misalnya: O3, PM2.5, SO2, CO, NO2, dll.) terhadap total jumlah kritis/polutan di setiap stasiun. Dalam kasus ini, parameter O3 (ozon) rata-rata menjadi parameter terbanyak di setiap stasiun.

DATA PREPARATION

1. Data Cleaning

2. Construct Data

3. Data Reduction

4. Data Transformation

DATA CLEANING

1. Penanganan Missing Value

- Pengecekan Missing Value

```
null_count = df.isna().sum()
null_ratio = null_count / len(df) * 100

null_df = pd.DataFrame({'Null Count': null_count.astype(int), 'Null Ratio %': null_ratio}, index=null_count.index)

print(null_df)
```

	Null Count	Null Ratio %
tanggal	0	0.000000
stasiun	0	0.000000
pm10	3137	14.314397
so2	2947	13.447410
co	2771	12.644308
o3	3025	13.803331
no2	2906	13.260324
max	29	0.132329
critical	2379	10.855578
categori	0	0.000000
pm25	20190	92.128679

Berdasarkan hasil penghitungan nilai yang kosong pada setiap kolom DataFrame dapat disimpulkan bahwa terdapat nilai/data yang hilang pada kolom pm10, so2, co, o3, no2, max, critical, dan pm25. Sehingga, kita perlu melakukan penanganan berupa penghapusan kolom atau baris.

DATA CLEANING

1. Penanganan Missing Value

- Hapus Missing Value

```
df = df.drop('pm25', axis=1)
```

Sesuai dengan hasil penghitungan jumlah nilai kosong pada tahapan sebelumnya, dapat kita lihat jika jumlah data kosong pada kolom pm25 berada diatas 70%, tepatnya 92.12% , maka kita harus menghapus kolom ini.

DATA CLEANING

1. Penanganan Missing Value

- Hapus Missing Value

```
[6] # Menghapus baris dengan nilai kosong pada kolom yang disebutkan  
columns_to_check = ['max', 'critical', 'pm10', 'so2', 'co', 'o3', 'no2']  
df = df.dropna(subset=columns_to_check)
```

Karena baris data pada kolom 'max' dan 'critical' berkaitan dengan baris data dari kolom-kolom parameter polusi ('pm10', 'so2', 'co', 'o3', dan 'no2'), sehingga jika dilakukan imputasi, maka data baru (hasil imputasi) pada kolom-kolom ini akan menjadi ambigu dan dapat menimbulkan kebingungan saat tahapan analisa selanjutnya.

DATA CLEANING

1. Penanganan Missing Value

- Pengecekan Ulang Missing Value

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio %'])
```

	Null Ratio %	
tanggal	0.0	
stasiun	0.0	
pm10	0.0	
so2	0.0	
co	0.0	
o3	0.0	
no2	0.0	
max	0.0	
critical	0.0	
categori	0.0	

Setelah dilakukan penanganan berupa penghapusan kolom dan imputasi, dapat kita ketahui bahwa dataset ini tidak memiliki data kosong lagi.

DATA CLEANING

2. Penanganan Duplicated Value

- Pengecekan Duplicated Value

```
df.duplicated()
0      False
1      False
2      False
3      False
4      False
...
21910   False
21911   False
21912   False
21913   False
21914   False
Length: 21915, dtype: bool
```

Melalui output disamping, dapat kita ketahui bahwa dataset "Air Quality Index in Jakarta (2010 - 2021)" tidak memiliki data duplikat pada setiap barisnya. Hal ini menunjukkan bahwa setiap baris dalam dataset ini memiliki informasi unik yang berbeda dengan baris lainnya. Sehingga, kita tidak perlu melakukan penanganan dataset berupa penghapusan kolom duplikat.

DATA CLEANING

3. Penanganan Outliers

- Pengecekan Outliers

```
results = []


cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

display(results_df)
```

Kolom	Persentase Outliers
pm10	1.618463
so2	3.254455
co	2.827929
o3	3.382997
no2	2.640958
max	5.036518



Berdasarkan hasil penghitungan outliers pada setiap kolom DataFrame dapat disimpulkan bahwa terdapat outliers, yaitu adanya data yang tidak biasa dengan tren umum dalam setiap variabel yang ditandai dengan adanya bulatan diluar garis boxplot. Outliers tersebut berada pada semua kolom. Masing-masing kolom memiliki persentase outliers dibawah 10% yang berarti kolom-kolom tersebut harus dilakukan penanganan dataset seperti imputasi outliers.

DATA CLEANING

3. Penanganan Outliers

- Imputasi Outliers

```
# Membuat list untuk menyimpan hasil perhitungan
results = []

# Memilih kolom dengan tipe data numerik
cols = df.select_dtypes(include=['float64', 'int64'])

# Perhitungan outliers
for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5 * iqr
    upper_bound = q3 + 1.5 * iqr

    # Imputasi outliers menggunakan metode flooring dan capping
    df[col] = df[col].apply(lambda x: lower_bound if x < lower_bound else (upper_bound if x > upper_bound else x))

    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers) / len(df)) * 100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})
```

Sesuai dengan hasil penghitungan outliers pada tahapan sebelumnya, dapat kita lihat jika persentase outliers pada semua kolom berada dibawah 10%, maka kita dapat mengimputasi/mengisi nilai-nilai yang outliers pada kolom ini dengan metode flooring dan capping. Metode flooring dan capping adalah teknik yang digunakan untuk mengatasi outliers dalam data dengan cara menggantikan nilai-nilai yang berada di luar rentang tertentu dengan nilai batas atas atau batas bawah yang telah ditentukan sebelumnya.

DATA CLEANING

3. Penanganan Outliers

- Pengecekan Ulang Outliers

```
results = []


cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

display(results_df)
```

Kolom	Persentase Outliers
pm10	0.0
so2	0.0
co	0.0
o3	0.0
no2	0.0
max	0.0



Setelah dilakukan penanganan outliers berupa imputasi, dapat kita ketahui bahwa dataset ini tidak memiliki outliers lagi.

CONSTRUCT DATA

- Melakukan Rekayasa Fitur

	tanggal	stasiun	pm10	so2	co	o3	no2	max	critical	categori	year
3289	2019-01-03	DKI1 (Bunderan HI)	16.0	16.0	5.0	29.0	4.0	29.0	O3	BAIK	2019
3295	2019-01-09	DKI1 (Bunderan HI)	61.0	15.0	28.0	147.5	8.0	137.5	O3	TIDAK SEHAT	2019
3296	2019-01-10	DKI1 (Bunderan HI)	41.0	13.0	26.0	128.0	8.0	128.0	O3	TIDAK SEHAT	2019
3300	2019-01-14	DKI1 (Bunderan HI)	65.0	12.0	32.0	99.0	9.0	99.0	O3	SEDANG	2019
3307	2019-01-21	DKI1 (Bunderan HI)	62.0	15.0	22.0	47.0	5.0	62.0	PM10	SEDANG	2019
...	...	...	...	...	...	...	...	...	...	...	...
21910	2021-12-27	DKI5 (Kebon Jeruk)	54.0	36.0	14.0	21.0	29.5	76.0	PM25	SEDANG	2021
21911	2021-12-28	DKI5 (Kebon Jeruk)	44.0	20.0	11.0	21.0	29.5	68.0	PM25	SEDANG	2021
21912	2021-12-29	DKI5 (Kebon Jeruk)	34.0	28.0	8.0	25.0	29.0	54.0	PM25	SEDANG	2021
21913	2021-12-30	DKI5 (Kebon Jeruk)	53.0	25.0	15.0	23.0	29.5	75.0	PM25	SEDANG	2021
21914	2021-12-31	DKI5 (Kebon Jeruk)	60.0	28.0	19.0	30.0	29.5	87.0	PM25	SEDANG	2021

4918 rows x 11 columns

Melalui output disamping, terdapat tambahan kolom yaitu "year". Penambahan kolom diatas bertujuan untuk memudahkan pengguna dalam melihat tahun-tahun pengukuran kualitas udara di Jakarta agar dataset semakin mudah untuk dipahami. Untuk tahun yang di construct hanya dari tahun 2019 hingga 2021 agar data-data yang digunakan untuk tahapan selanjutnya menggunakan data dari tahun-tahun terbaru.

DATA REDUCTION

- Mengurangi Fitur-fitur yang kurang relevan

	stasiun	pm10	so2	co	o3	no2	max	critical	categori	year
0	DKI1 (Bunderan HI)	29.0	15.0	5.0	64.976601	13.00000	29.0	PM10	BAIK	2019
1	DKI1 (Bunderan HI)	24.0	17.0	5.0	64.976601	6.00000	24.0	PM10	BAIK	2019
2	DKI1 (Bunderan HI)	16.0	16.0	5.0	29.000000	4.00000	29.0	O3	BAIK	2019
3	DKI1 (Bunderan HI)	38.0	18.0	8.0	24.000000	12.36553	38.0	PM10	BAIK	2019
4	DKI1 (Bunderan HI)	37.0	29.0	16.0	64.976601	16.00000	37.0	PM10	BAIK	2019
...	...	...	...	...	...	...	...	...	...	...
3508	DKI5 (Kebon Jeruk)	24.0	17.0	8.0	27.000000	10.00000	27.0	CO	BAIK	2021
3509	DKI5 (Kebon Jeruk)	41.0	17.0	19.0	29.000000	8.00000	41.0	PM10	BAIK	2021
3510	DKI5 (Kebon Jeruk)	57.0	24.0	15.0	21.000000	27.00000	57.0	PM10	SEDANG	2021
3511	DKI5 (Kebon Jeruk)	54.0	23.0	13.0	25.000000	22.00000	54.0	PM10	SEDANG	2021
3512	DKI5 (Kebon Jeruk)	53.0	25.0	12.0	32.000000	21.00000	53.0	PM10	SEDANG	2021

3513 rows x 10 columns

Melalui output disamping, terdapat pengurangan/penghapusan kolom, yaitu kolom "tanggal". Hal ini dilakukan agar tidak menimbulkan kebingungan dalam membaca dataset karena adanya kolom "year", dimana kolom "year" berisi tahun pengukuran kualitas udara yang diambil dari tahun pada kolom "tanggal" itu sendiri. Pada tahapan ini, kami juga menghapus baris-baris yang memiliki nilai "pm25" dari kolom "critical" dan "tidak ada data" dari kolom "categori" karena kolom "pm25" telah dihapus pada tahapan hapus missing value, jadi tidak ada korelasinya lagi jika terdapat nilai "pm25" pada kolom "critical" yang menunjukkan parameter/kolom dengan nilai tertinggi. Selain itu, kita tidak memerlukan baris dari kolom "categori" yang memiliki nilai "tidak ada data".

DATA TRANSFORMATION

- Mapping

	stasiun	pm10	so2	co	o3	no2	max	critical	categori	year
0	0	16.0	16.0	5.0	29.0	4.0	29.0	3	0	2019
1	0	61.0	15.0	28.0	147.5	8.0	137.5	3	2	2019
2	0	41.0	13.0	26.0	128.0	8.0	128.0	3	2	2019
3	0	65.0	12.0	32.0	99.0	9.0	99.0	3	1	2019
4	0	62.0	15.0	22.0	47.0	5.0	62.0	0	1	2019
...	...	...	...	...	...	...	...	...	...	...
3212	4	24.0	17.0	8.0	27.0	10.0	27.0	2	0	2021
3213	4	41.0	17.0	19.0	29.0	8.0	41.0	0	0	2021
3214	4	57.0	24.0	15.0	21.0	29.0	57.0	0	1	2021
3215	4	54.0	23.0	13.0	25.0	22.0	54.0	0	1	2021
3216	4	53.0	25.0	12.0	32.0	21.0	53.0	0	1	2021

3217 rows x 10 columns

Melalui output disamping, terdapat perubahan data pada kolom "categori", "stasiun", dan "critical". Perubahan data yang dimaksud yaitu perubahan data kategorikal menjadi nilai numerik. Dimana awalnya nilai-nilai pada kolom "categori" yaitu "baik", "sedang", "tidak sehat", "sangat tidak sehat", dan "berbahaya", pada kolom "stasiun" yaitu "DKI1 (Bunderan HI)", "DKI2 (Kelapa Gading)", "DKI3 (Jagakarsa)", "DKI4 (Lubang Buaya)", dan "DKI5 (Kebon Jeruk)" dan pada kolom "critical" yaitu "PM10", "SO2", "CO", "O3", dan "NO2". Namun setelah dilakukan mapping, maka nilai dalam kolom tersebut berubah menjadi numerik yang merepresentasikan kategori awal. Contohnya seperti pada kolom "categori", nilai "baik" diubah menjadi angka 0, nilai "DKI2 (Kelapa Gading)" pada kolom "stasiun" diubah menjadi angka 1, dan nilai "co2" pada kolom "critical" diubah menjadi angka 2. Hal ini dilakukan agar model algoritma lebih optimal bekerja ketika menerima input data berupa angka dengan skala yang seragam.

-

MODELLING

1. Select Modelling Technique

2. Modelling Associate

3. Modelling Predict

4. Visualisasi

SELECT MODELLING TECHNIQUE

Pada tahapan modelling kali ini, kita akan menggunakan teknik permodelan klastering (asosiatif). Melalui teknik ini, kita akan menganalisis kualitas udara menggunakan 1 algoritma yaitu K-Means.

Alasan menggunakan algoritma KMeans karena kemudahan implementasinya dan kemampuannya untuk menangani sejumlah besar data. Dalam konteks analisis kualitas udara yang melibatkan data multi-dimensi dan besar seperti dalam studi kasus ini, efisiensi komputasi sangat penting, dan K-Means cenderung memiliki kinerja yang baik.


Setelah melakukan klastering, kita akan melakukan teknik permodelan klasifikasi (prediktif). Melalui teknik ini, kita akan memprediksi klaster yang telah dibangun pada tahapan teknik permodelan klastering (asosiatif) menggunakan 2 algoritma, yaitu GaussianNB dan K-Nearest Neighbors.

Alasan menggunakan algoritma KNN karena KNN adalah salah satu algoritma yang paling sederhana dan mudah dipahami dalam machine learning. Algoritma ini hanya memerlukan perhitungan jarak antara titik data untuk membuat prediksi.

Alasan menggunakan algoritma GNB karena GNB adalah algoritma yang cepat dalam pemrosesan dan dapat dengan cepat memberikan prediksi bahkan pada dataset yang besar.

MODELLING ASSOCIATE

- Pre-Processing (Validasi Silang)



Output disamping merupakan implementasi metode siku (elbow method) untuk menentukan jumlah optimal dari kluster dalam algoritma KMeans. Plot diatas akan menunjukkan bagaimana nilai inertia berubah seiring dengan jumlah kluster. Tujuan dari metode siku adalah untuk menemukan titik "siku" di plot, yaitu titik dimana penurunan nilai inertia tidak lagi signifikan saat jumlah kluster ditambahkan. Titik siku ini menunjukkan jumlah kluster optimal. Berdasarkan hasil plot diatas, dapat kita lihat jika titik "siku" berada di angka 6. Dapat kita simpulkan jika jumlah kluster optimal dalam algoritma KMeans adalah 6.

MODELLING ASSOCIATE

- Build Model (K-Means)

	stasiun	pm10	so2	co	o3	no2	max	critical	categori	year	kmeans_label
0	0	16.0	16.0	5.0	29.0	4.0	29.0	3	0	2019	3
1	0	61.0	15.0	28.0	147.5	8.0	137.5	3	2	2019	0
2	0	41.0	13.0	26.0	128.0	8.0	128.0	3	2	2019	0
3	0	65.0	12.0	32.0	99.0	9.0	99.0	3	1	2019	1
4	0	62.0	15.0	22.0	47.0	5.0	62.0	0	1	2019	4
...	...	...	...	...	...	...	...	...	...	...	...
3212	4	24.0	17.0	8.0	27.0	10.0	27.0	2	0	2021	3
3213	4	41.0	17.0	19.0	29.0	8.0	41.0	0	0	2021	3
3214	4	57.0	24.0	15.0	21.0	29.0	57.0	0	1	2021	2
3215	4	54.0	23.0	13.0	25.0	22.0	54.0	0	1	2021	1
3216	4	53.0	25.0	12.0	32.0	21.0	53.0	0	1	2021	5

3217 rows x 11 columns

Output disamping merupakan implementasi Build Model menggunakan algoritma KMeans. Berdasarkan output ini, kita membuat objek model KMeans dengan menggunakan jumlah kluster yang telah ditentukan dari perhitungan validasi silang (elbow method), yaitu 6 kluster 'n_clusters=6'.

MODELLING PREDICT

- Pre-Processing

```
X = df4.drop(["kmeans_label"], axis=1)
y = df4["kmeans_label"]
```

Source Code diatas merupakan implementasi dari proses pemisahan data menjadi data latih (data train) dan data pengujian (testing data). Pada kode ini, kita akan menghapus kolom 'kmeans_label' karena kolom ini merupakan label target yang akan kita prediksi dan kita akan menetapkan label target ke dalam variabel 'y'. Variabel 'y' akan berisi nilai target yang akan diprediksi oleh model algoritma.

MODELLING PREDICT

- Pre-Processing

```
import numpy as np
import pandas as pd

def manual_train_test_split(X, y, test_size=0.2, random_state=None):
    if random_state is not None:
        np.random.seed(random_state)

    num_samples = len(X)
    indices = np.arange(num_samples)
    np.random.shuffle(indices)

    test_size = int(test_size * num_samples)

    X_train = X.iloc[indices[:-test_size]]
    X_test = X.iloc[indices[-test_size:]]
    y_train = y.iloc[indices[:-test_size]]
    y_test = y.iloc[indices[-test_size:]]

    return X_train, X_test, y_train, y_test

# Contoh penggunaan
X_train, X_test, y_train, y_test = manual_train_test_split(X, y, test_size=0.2, random_state=42)

print(X_train.shape)
print(X_test.shape)

(2574, 10)
(643, 10)
```

Pada kode ini, kita akan membagi data menjadi empat subset secara manual: `x_train` (fitur-fitur data latih), `x_test` (fitur-fitur data pengujian), `y_train` (label data latih), dan `y_test` (label data pengujian). Argumen `'test_size=0.2'` menunjukkan bahwa 20% atau 643 kolom pada dataframe ini akan digunakan sebagai data pengujian, sedangkan 80% atau 2574 kolom akan digunakan sebagai data latih. Terakhir, argumen `'random_state=42'` digunakan untuk memastikan bahwa pembagian data akan konsisten setiap kali kode dijalankan.

MODELLING PREDICT

- Pipeline

```
num_features = ['pm10', 'so2', 'co', 'o3', 'no2']
cat_features = ['stasiun', 'critical', 'kategori', 'year']

from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, OneHotEncoder

num_pipeline = Pipeline(
    steps=[
        ('num_imputer', SimpleImputer()),
        ('scaler', StandardScaler()),
    ]
)

cat_pipeline = Pipeline(
    steps=[
        ('cat_imputer', SimpleImputer(strategy='most_frequent')),
        ('onehot', OneHotEncoder()),
    ]
)

from sklearn.compose import ColumnTransformer

preprocessor = ColumnTransformer(
    transformers=[
        ('num_pipeline', num_pipeline, num_features),
        ('cat_pipeline', cat_pipeline, cat_features),
    ]
)
```

Pipeline adalah kelas yang memungkinkan kita menggabungkan beberapa langkah pemrosesan data dan model ke dalam satu objek. Dengan menggunakan pipeline, langkah-langkah pemrosesan data dan model akan diterapkan secara otomatis dan terurut saat kita memanggil metode `fit()` untuk melatih model dan `predict()` untuk membuat prediksi pada data baru. Contoh penggunaan Pipeline dan ColumnTransformer dalam scikit-learn untuk memproses dan menyusun fitur-fitur numerik dan kategorikal dalam sebuah dataset sebelum memasukkannya ke dalam model machine learning.

MODELLING PREDICT

- Build Model (K-Nearest Neighbors)

```
hasil_knn  
  
array([3, 0, 0, ..., 2, 1, 5])
```

Kode di atas merupakan output dari membangun sebuah pipeline yang meliputi langkah-langkah pemrosesan data dan penggunaan model KNN yang telah dibuat secara kustom (KNNClassifier). Kode tersebut menggabungkan langkah-langkah pemrosesan data dan model KNN ke dalam satu pipeline yang dapat digunakan untuk melatih model dan membuat prediksi secara mudah dan terstruktur.

MODELLING PREDICT

- Build Model (Gaussian Naive Bayes)

```
hasil_gnb  
  
array([3, 0, 0, ..., 2, 5, 5])
```

Kode di atas merupakan output dari membangun sebuah pipeline yang meliputi langkah-langkah pemrosesan data dan penggunaan model GNB yang telah dibuat secara kustom (MyGaussianNB). Kode tersebut menggabungkan langkah-langkah pemrosesan data dan model GNB ke dalam satu pipeline yang dapat digunakan untuk melatih model dan membuat prediksi secara mudah dan terstruktur.

- Begins and Compare Predict

VISUALISASI

Air Quality Index

PLUTUS
IAS

AQI Category	AQI	Concentration Range*							
		PM ₁₀	PM _{2.5}	NO ₂	O ₃	CO	SO ₂	NH ₃	Pb
Good	0-50	0-50	0-30	0-40	0-50	0-1.0	0-40	0-200	0-0.5
Satisfactory	51 - 100	51-100	31-60	41-80	51-100	1.1-2.0	41-80	201-400	0.5-1.0
Moderately Polluted	101-200	101-250	61-90	81-180	101-168	2.1-10	81-380	401-800	1.1-2.0
Poor	201-300	251-350	91-120	181-280	169-208	10-17	381-800	801-1200	2.1-3.0
Very Poor	301-400	351-430	121-250	281-400	209-748*	17-34	801-1600	1200-1800	3.1-3.5
Severe	401-500	430+	250+	400+	748+*	34+	1600+	1800+	3.5+

* CO in mg/m³ and other pollutants in µg/m³; 24-hourly average values for PM₁₀, PM_{2.5}, NO₂, SO₂, NH₃, and Pb, and 8-hourly values for CO and O₃.

VISUALISASI

- Analisis Cluster (Cluster 0)

stasiun	critical	categori	year
0	4	3	2 2019

	pm10	so2	co	o3	no2	kmeans_label
count	478.000000	478.000000	478.000000	478.000000	478.000000	478.0
mean	63.566946	18.794979	16.884937	120.066946	9.59205	0.0
std	10.404488	6.644603	6.800261	19.103539	3.60975	0.0
min	32.000000	6.000000	3.000000	84.000000	2.00000	0.0
25%	58.000000	13.000000	12.000000	104.000000	7.00000	0.0
50%	64.000000	20.000000	16.000000	118.500000	9.00000	0.0
75%	70.000000	23.000000	20.000000	137.000000	11.00000	0.0
max	99.500000	38.000000	49.500000	147.500000	26.00000	0.0

VISUALISASI

- Analisis Cluster (Cluster 0)

- Terdapat 478 data pada cluster 0.
- O3 (ozon) menjadi parameter polusi dengan rata-rata tertinggi dan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 0.
- NO2 (nitrogen dioksida) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 0.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Buruk'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Cukup tercemar'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI5 (Kebon Jeruk) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 0.
- Kategori 'Tidak Sehat' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 0.
- Tahun 2019 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 0.

VISUALISASI

- Analisis Cluster (Cluster 1)

```
stasiun critical kategori year
0      0      3      1 2019
```

	pm10	so2	co	o3	no2	kmeans_label
count	573.000000	573.000000	573.000000	573.000000	573.000000	573.0
mean	56.486911	15.568935	28.708551	62.856894	12.663176	1.0
std	10.213041	5.900475	8.217256	20.564850	4.301161	0.0
min	24.000000	2.000000	12.000000	6.000000	3.000000	1.0
25%	51.000000	11.000000	23.000000	47.000000	9.000000	1.0
50%	56.000000	15.000000	27.000000	63.000000	12.000000	1.0
75%	63.000000	20.000000	34.000000	78.000000	16.000000	1.0
max	93.000000	37.000000	49.500000	128.000000	25.000000	1.0

VISUALISASI

- Analisis Cluster (Cluster 1)

- Terdapat 573 data pada cluster 1.
- O3 (Ozon) menjadi parameter polusi dengan rata-rata tertinggi dan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 1.
- NO2 (Nitrogen dioksida) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 1.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Sangat Buruk'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI1 (Bundaran HI) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 1.
- Kategori 'Sedang' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 1.
- Tahun 2019 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 1.

VISUALISASI

- Analisis Cluster (Cluster 2)

```
stasiun critical kategori year
0      4      2      1 2020
```

	pm10	so2	co	o3	no2	kmeans_label
count	101.000000	101.000000	101.000000	101.000000	101.000000	101.0
mean	53.198020	20.702970	39.356436	15.821782	28.801980	2.0
std	14.159816	14.360741	13.819250	18.208457	1.941751	0.0
min	18.000000	4.000000	9.000000	3.000000	21.000000	2.0
25%	45.000000	11.000000	26.000000	7.000000	29.500000	2.0
50%	54.000000	15.000000	49.500000	9.000000	29.500000	2.0
75%	62.000000	26.000000	49.500000	13.000000	29.500000	2.0
max	83.000000	49.000000	49.500000	92.000000	29.500000	2.0

VISUALISASI

- Analisis Cluster (Cluster 2)

- Terdapat 101 data pada cluster 2.
- PM10 menjadi parameter polusi dengan rata-rata tertinggi diantara parameter polusi lainnya pada cluster 2.
- CO (Karbon monoksida) menjadi parameter polusi dengan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 2.
- O3 (Ozon) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 2.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Berbahaya/Parah'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI5 (Kebon Jeruk) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 2.
- Kategori 'Sedang' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 2.
- Tahun 2020 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 2.

VISUALISASI

- Analisis Cluster (Cluster 3)

stasiun	critical	categori	year
0	4	3	0 2020

	pm10	so2	co	o3	no2	kmeans_label
count	596.000000	596.000000	596.000000	596.000000	596.000000	596.0
mean	33.726510	15.493289	12.473154	47.442953	7.597315	3.0
std	8.661896	7.809816	5.875540	18.856694	3.594897	0.0
min	7.500000	1.000000	3.000000	12.000000	1.000000	3.0
25%	27.000000	9.000000	8.000000	33.000000	5.000000	3.0
50%	34.000000	16.000000	12.000000	45.000000	7.000000	3.0
75%	40.000000	20.000000	16.000000	62.000000	9.000000	3.0
max	50.000000	44.000000	36.000000	105.000000	20.000000	3.0

VISUALISASI

- Analisis Cluster (Cluster 3)

- Terdapat 596 data pada cluster 3.
- O3 (Ozon) menjadi parameter polusi dengan rata-rata tertinggi dan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 3.
- NO2 (Nitrogen dioksida) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 3.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Buruk'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI5 (Kebon Jeruk) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 3.
- Kategori 'Baik' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 3.
- Tahun 2020 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 3.

VISUALISASI

- Analisis Cluster (Cluster 4)

stasiun	critical	categori	year
0	1	3	1
			2019

	pm10	so2	co	o3	no2	kmeans_label
count	840.000000	840.000000	840.000000	840.000000	840.000000	840.0
mean	59.134524	13.172619	13.098810	69.864286	9.016667	4.0
std	8.565933	5.002261	4.910498	16.745965	2.965388	0.0
min	37.000000	1.000000	3.000000	25.000000	2.000000	4.0
25%	53.000000	9.000000	9.000000	58.000000	7.000000	4.0
50%	58.000000	13.000000	13.000000	70.000000	9.000000	4.0
75%	65.000000	18.000000	17.000000	83.000000	11.000000	4.0
max	89.000000	22.000000	27.000000	112.000000	23.000000	4.0

VISUALISASI

- Analisis Cluster (Cluster 4)

- Terdapat 840 data pada cluster 4.
- O3 (Ozon) menjadi parameter polusi dengan rata-rata tertinggi dan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 4.
- NO2 (Nitrogen dioksida) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 4.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Buruk'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI2 (Kelapa Gading) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 4.
- Kategori 'Sedang' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 4.
- Tahun 2019 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 4.

VISUALISASI

- Analisis Cluster (Cluster 5)

```
stasiun critical kategori year
0      3      0      1 2020
```

	pm10	so2	co	o3	no2	kmeans_label
count	629.000000	629.000000	629.000000	629.000000	629.000000	629.0
mean	60.488871	29.761526	14.001590	61.804452	8.920509	5.0
std	12.112886	7.107481	5.567049	18.470623	3.995225	0.0
min	28.000000	21.000000	4.000000	13.000000	2.000000	5.0
25%	53.000000	24.000000	10.000000	49.000000	6.000000	5.0
50%	60.000000	28.000000	13.000000	61.000000	8.000000	5.0
75%	68.000000	34.000000	17.000000	76.000000	11.000000	5.0
max	99.500000	49.000000	41.000000	113.000000	26.000000	5.0

VISUALISASI

- Analisis Cluster (Cluster 5)

- Terdapat 629 data pada cluster 5.
- O3 (Ozon) menjadi parameter polusi dengan rata-rata tertinggi diantara parameter polusi lainnya pada cluster 5.
- PM10 menjadi parameter polusi dengan skor pengukuran tertinggi terbanyak diantara parameter polusi lainnya pada cluster 5.
- NO2 (Nitrogen dioksida) menjadi parameter polusi dengan rata-rata terendah diantara parameter polusi lainnya pada cluster 5.
- Berdasarkan hasil rata-rata dari PM10, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari SO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Berdasarkan hasil rata-rata dari CO, parameter polusi ini masuk ke dalam kategori AQI 'Buruk'.
- Berdasarkan hasil rata-rata dari O3, parameter polusi ini masuk ke dalam kategori AQI 'Memuaskan'.
- Berdasarkan hasil rata-rata dari NO2, parameter polusi ini masuk ke dalam kategori AQI 'Baik'.
- Stasiun DKI4 (Lubang Buaya) menjadi stasiun pengukuran terbanyak diantara stasiun pengukuran lainnya pada cluster 5.
- Kategori 'Sedang' menjadi kategori udara terbanyak diantara kategori udara lainnya pada cluster 5.
- Tahun 2020 menjadi tahun pengukuran terbanyak diantara tahun pengukuran lainnya pada cluster 5.




EVALUATION

1. Evaluate Results

2. Review Process

EVALUATE RESULTS

- Confusion Matrix



Sumbu X pada matrix diatas menunjukkan predicted values dan sumbu Y menunjukkan actual values. Visualisasi Confusion Matrix ini membantu dalam mengevaluasi kinerja kedua model klasifikasi dengan melihat seberapa baik mereka dapat memprediksi kelas yang benar dan seberapa sering mereka membuat kesalahan.

EVALUATE RESULTS

- Akurasi, Presisi, Recall, F1-Score, ROC AUC Score KNN

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

# Initialize the K-Nearest Neighbors (KNN) model
knn_model = KNNClassifier()

# Fit the model to the training data
knn_model.fit(X_train, y_train)

# Compute predictions using the fitted model
predictions = knn_model.predict(X_test)

# Compute evaluation metrics
accuracy = accuracy_score(y_test, predictions)
precision = precision_score(y_test, predictions, average='macro')
recall = recall_score(y_test, predictions, average='macro')
f1 = f1_score(y_test, predictions, average='macro')

# Display the evaluation metrics
print("Accuracy:", accuracy)
print("Precision:", precision)
print("Recall:", recall)
print("F1 Score:", f1)

# Compute predicted probabilities for each class
knn_probs = knn_model.predict_proba(X_test)

# Compute the ROC-AUC score for each class
roc_score = roc_auc_score(y_test, knn_probs, multi_class='ovr')

# Display the ROC-AUC score for KNN
print("ROC-AUC Score for K-Nearest Neighbors (KNN):", roc_score)
```

```
Accuracy: 0.9253499222395023
Precision: 0.9363946297386998
Recall: 0.9208844849001228
F1 Score: 0.9279410150909962
ROC-AUC Score for K-Nearest Neighbors (KNN): 0.9887219950626914
```

EVALUATE RESULTS

- Akurasi, Presisi, Recall, F1-Score, ROC AUC Score GNB

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

# Initialize the Gaussian Naive Bayes model
gnb_model = MyGaussianNB()

# Fit the model to the training data
gnb_model.fit(X_train, y_train)

# Compute predictions using the fitted model
predictions = gnb_model.predict(X_test)

# Compute probability estimates for each class
gnb_probs = gnb_model.predict_proba(X_test)


# Compute evaluation metrics
accuracy = accuracy_score(y_test, predictions)
precision = precision_score(y_test, predictions, average='macro')
recall = recall_score(y_test, predictions, average='macro')
f1 = f1_score(y_test, predictions, average='macro')
roc_score = roc_auc_score(y_test, gnb_probs, multi_class='ovr')

# Display the evaluation metrics
print("Accuracy:", accuracy)
print("Precision:", precision)
print("Recall:", recall)
print("F1 Score:", f1)
print("ROC-AUC Score for Gaussian Naive Bayes:", roc_score)
```

```
Accuracy: 0.8569206842923794
Precision: 0.8810481005561096
Recall: 0.8742569921178759
F1 Score: 0.8739019339800728
ROC-AUC Score for Gaussian Naive Bayes: 0.9794153860561918
```

EVALUATE RESULTS


- ROC Curve



Pada ROC Curve diatas, dapat kita simpulkan lagi bahwa model algoritma yang optimal dalam melakukan modelling predict/klasifikasi adalah algoritma K-Nearest Neighbors dengan rentang nilai micro-average ROC-AUC dari setiap cluster sebesar 0.97 - 1.00.

REVIEW PROCESS


- Cross Validation



Melalui grafik Cross-Validation Scores untuk kedua model algoritma diatas, dapat kita buktikan bahwa algoritma K-Nearest Neighbors merupakan algoritma yang optimal, sesuai dengan perhitungan ditahapan sebelumnya karena setiap data pada algoritma ini dilatih hingga sebanyak 5 kali, perubahan performa (garis naik dan turunnya) tidak berubah drastis.

REVIEW PROCESS


- Feature Selection KNN



fitur-fitur teratas yang berpengaruh terhadap hasil analisis menggunakan algoritma KNN adalah kolom 'max', 'o3', dan 'kategori'. Kolom 'max' berisi nilai tertinggi di antara semua parameter dalam pengukuran kualitas udara. Kolom 'o3' berisi kadar ozon (O3), salah satu parameter yang diukur dalam pengukuran kualitas udara. Kolom 'kategori' berisi kategori kualitas udara berdasarkan Indeks Standar Polusi Udara dalam pengukuran kualitas udara.

REVIEW PROCESS

- Feature Selection GNB



fitur-fitur teratas yang berpengaruh terhadap hasil analisis menggunakan algoritma GNB adalah kolom 'max', 'o3', dan 'kategori'. Kolom 'max' berisi nilai tertinggi di antara semua parameter dalam pengukuran kualitas udara. Kolom 'o3' berisi kadar ozon (O3), salah satu parameter yang diukur dalam pengukuran kualitas udara. Kolom 'kategori' berisi kategori kualitas udara berdasarkan Indeks Standar Polusi Udara dalam pengukuran kualitas udara.

REVIEW PROCESS

Tuning Hyperparameter KNN

```
from sklearn.metrics import accuracy_score

# Inisialisasi model KNN sebelum penyetelan parameter
knn_before_tuning = KNNClassifier()

# Latih model KNN sebelum penyetelan parameter
knn_before_tuning.fit(X_train, y_train)

# Lakukan prediksi menggunakan model KNN sebelum penyetelan parameter
predictions_before_tuning = knn_before_tuning.predict(X_test)

# Hitung akurasi dari prediksi sebelum penyetelan parameter
accuracy_before_tuning = accuracy_score(y_test, predictions_before_tuning)

# Inisialisasi model KNN setelah penyetelan parameter (jika ada)
# Misalnya, Anda ingin menggunakan model KNN yang sama tanpa penyetelan parameter
knn_after_tuning = KNNClassifier()

# Latih model KNN setelah penyetelan parameter (jika ada)
knn_after_tuning.fit(X_train, y_train)

# Lakukan prediksi menggunakan model KNN setelah penyetelan parameter (jika ada)
predictions_after_tuning = knn_after_tuning.predict(X_test)

# Hitung akurasi dari prediksi setelah penyetelan parameter (jika ada)
accuracy_after_tuning = accuracy_score(y_test, predictions_after_tuning)

# Tampilkan hasil
print("Accuracy before tuning:", accuracy_before_tuning)
print("Accuracy after tuning:", accuracy_after_tuning)
```

```
Accuracy before tuning: 0.9253499222395023
Accuracy after tuning: 0.9253499222395023
```

Hasil tersebut menunjukkan performa model KNN sebelum dan setelah dilakukan penyetelan parameter (tuning). Dalam konteks yang diberikan, kedua nilai akurasi tersebut sama, yaitu 0.925. Hal ini mengindikasikan bahwa setelah dilakukan penyetelan parameter (tuning), kinerja model KNN tidak mengalami perubahan yang signifikan.

REVIEW PROCESS

Tuning Hyperparameter GNB

```
from sklearn.model_selection import GridSearchCV

param_grid = {
    'var_smoothing': np.logspace(0, -9, num=100)
}

grid_search = GridSearchCV(estimator= MyGaussianNB(), param_grid=param_grid, cv=5)
grid_search.fit(X_train, y_train)

y_pred_tuned = grid_search.best_estimator_.predict(X_test)

acc_before_tuning = gnb_model.score(X_test, y_test)
print("Akurasi sebelum tuning:", acc_before_tuning)

acc_after_tuning = grid_search.best_estimator_.score(X_test, y_test)
print("Akurasi setelah tuning:", acc_after_tuning)
```

```
Akurasi sebelum tuning: 0.8569206842923794
Akurasi setelah tuning: 0.8569206842923794
```

Hasil tersebut menunjukkan performa model GNB sebelum dan setelah dilakukan penyetelan parameter (tuning). Dalam konteks yang diberikan, kedua nilai akurasi tersebut sama, yaitu 0.856. Hal ini mengindikasikan bahwa setelah dilakukan penyetelan parameter (tuning), kinerja model GNB tidak mengalami perubahan yang signifikan.



KESIMPULAN

Berdasarkan hasil pada tahapan Feature Selection, parameter polusi yang paling berpengaruh terhadap hasil analisa kualitas udara yaitu O3 atau Ozon.

Dikutip dari WRI Indonesia atau Yayasan Institut Sumber Daya Dunia yang berfokus pada lima tantangan utama dunia saat ini, salah satunya yaitu Iklim, sinar matahari dan tingginya temperatur memperburuk ozon permukaan (O3), jenis ozon yang lazim dirasakan sebagai kabut asap, dapat berdampak pada fungsi paru-paru dan jantung. Polutan ini terbentuk dari reaksi kimiawi antara Senyawa Organik yang mudah menguap atau Volatile Organic Compound dengan Metana dan Nitrogen Oksida, yang diemisikan oleh kendaraan, industri, dan sumber-sumber lainnya, dikombinasikan dengan adanya radiasi matahari.

Sumber:

<https://wri-indonesia.org/id/wawasan/7-hal-yang-perlu-diketahui-tentang-darurat-polusi-udara-di-jakarta-0>

