



Prepared by Group 1

Mid Exam

Data Analytics for Business - Bitlabs

26 October 2024



Team Members



Tsurayya Salsabila
Leader



Lidia Aprilia Putri
Member



M. Tegar Pandiriyan
Member



Agenda



Business Process Analysis

Python Pre-processing

SQL Query

Exploratory Data Analysis

A/B Testing



Business Process Analysis

Identifikasi Masalah:

1. Tingkat Pembatalan yang Signifikan

Rata-rata tingkat pembatalan mencapai sekitar 37%, artinya lebih dari sepertiga dari seluruh reservasi yang dilakukan berakhir dengan pembatalan. Berbagai faktor dapat berkontribusi pada tingginya tingkat pembatalan ini, termasuk perubahan rencana tamu, kesalahan dalam proses reservasi, atau kurangnya fleksibilitas dalam menangani perubahan permintaan.



CANCELLED

Business Process Analysis

Identifikasi Masalah:

2. Variabilitas dalam Lead Time

Variasi lead time yang besar bisa menjadi faktor pendorong pembatalan, terutama bagi tamu yang memesan terlalu jauh di muka. Ketidakpastian dalam rencana perjalanan, yang mungkin berubah dalam rentang waktu yang panjang, dapat mendorong mereka untuk membatalkan reservasi. Hotel mungkin perlu mempertimbangkan kebijakan dinamis yang lebih adaptif terhadap perubahan lead time.



Business Process Analysis


Identifikasi Masalah:

3. Efektivitas Penanganan Permintaan Khusus

Data menunjukkan bahwa rata-rata tamu membuat sekitar 0,57 permintaan khusus per reservasi. Menariknya, terdapat korelasi negatif dengan nilai - 0,23. Ini mengindikasikan bahwa semakin banyak permintaan khusus yang diajukan tamu, semakin kecil kemungkinan mereka untuk membatalkan reservasi.




BPMN Diagram



Python Pre-processing

Flowchart



Flowchart disamping menggambarkan alur data preparation, dimulai dengan memuat data ke Google Colab dan kemudian memeriksa beberapa aspek kualitas data. Pertama, sistem memeriksa apakah ada duplikasi data dan menghapusnya jika ditemukan. Selanjutnya, diperiksa apakah ada inkonsistensi dalam tipe data, di mana tipe yang tidak sesuai akan diperbaiki. Setelah itu, data yang kosong (missing values) akan dicek dan diatasi dengan menghapus atau mengimputasi nilai. Langkah terakhir adalah mengecek apakah terdapat outliers, yang akan ditangani dengan metode seperti penggantian menggunakan rata-rata. Setelah semua tahap ini dilalui, data dianggap bersih dan siap untuk analisis lebih lanjut.

Python Pre-processing

Duplicated Values

```
Jumlah duplikasi: 0
```

Output di atas menunjukkan bahwa jumlah duplikasi dalam dataset adalah 0, artinya tidak ada baris yang terdeteksi identik atau berulang di dalam DataFrame. Ini berarti setiap baris dalam dataset memiliki data yang unik, sehingga tidak diperlukan tindakan lebih lanjut untuk menghapus duplikasi.

Python Pre-processing

Inconsistent Values

hotel	object
is_canceled	int64
lead_time	float64
arrival_date_year	int64
arrival_date_month	object
arrival_date_week_number	int64
arrival_date_day_of_month	int64
stays_in_weekend_nights	float64
stays_in_week_nights	int64
adults	float64
children	float64
babies	int64
meal	object
country	object
market_segment	object
distribution_channel	object
is_repeated_guest	int64
previous_cancellations	int64

previous_bookings_not_canceled	int64
reserved_room_type	object
assigned_room_type	object
booking_changes	int64
deposit_type	object
agent	float64
company	float64
days_in_waiting_list	int64
customer_type	object
adr	float64
required_car_parking_spaces	int64
total_of_special_requests	float64
reservation_status	object
reservation_status_date	datetime64[ns]
name	object
email	object
phone-number	object
credit_card	object

Beberapa kolom yang berhubungan dengan informasi tentang hotel, reservasi, dan karakteristik tamu dicatat sebagai 'object', misalnya kolom 'hotel', 'country', 'market_segment', 'reserved_room_type', dan 'deposit_type'. Ada juga beberapa kolom numerik yang menggunakan tipe 'int64' dan 'float64', misalnya 'is_canceled', 'lead_time', 'adults', 'children', serta 'adr' (Average Daily Rate). Kolom 'reservation_status_date' disimpan sebagai 'datetime64[ns]' untuk mewakili data tanggal.

Python Pre-processing

Missing Values

hotel	0	0.0
is_canceled	0	0.0
lead_time	0	0.0
arrival_date_year	0	0.0
arrival_date_month	0	0.0
arrival_date_week_number	0	0.0
arrival_date_day_of_month	0	0.0
stays_in_weekend_nights	0	0.0
stays_in_week_nights	0	0.0
adults	0	0.0
children	0	0.0
babies	0	0.0
meal	0	0.0
country	0	0.0
market_segment	0	0.0
distribution_channel	0	0.0
is_repeated_guest	0	0.0
previous_cancellations	0	0.0

previous_bookings_not_canceled	0	0.0
reserved_room_type	0	0.0
assigned_room_type	0	0.0
booking_changes	0	0.0
deposit_type	0	0.0
agent	0	0.0
days_in_waiting_list	0	0.0
customer_type	0	0.0
adr	0	0.0
required_car_parking_spaces	0	0.0
total_of_special_requests	0	0.0
reservation_status	0	0.0
reservation_status_date	0	0.0
name	0	0.0
email	0	0.0
phone-number	0	0.0
credit_card	0	0.0

Output di sampling menunjukkan bahwa pada tahap persiapan data (data prep), tidak ditemukan adanya nilai yang hilang (missing value) pada semua fitur (kolom) yang dianalisis, yaitu mulai dari fitur 'hotel' hingga 'credit_card'.

Python Pre-processing

Outliers Values

	Jumlah Outlier	Persentase Outlier (%)
Unnamed: 0	0	0.0
is_canceled	0	0.0
lead_time	0	0.0
arrival_date_year	0	0.0
arrival_date_week_number	0	0.0
arrival_date_day_of_month	0	0.0
stays_in_weekend_nights	0	0.0
stays_in_week_nights	0	0.0
adults	0	0.0
children	0	0.0
babies	0	0.0
is_repeated_guest	0	0.0
previous_cancellations	0	0.0
previous_bookings_not_canceled	0	0.0
booking_changes	0	0.0
agent	0	0.0
days_in_waiting_list	0	0.0
adr	0	0.0
required_car_parking_spaces	0	0.0
total_of_special_requests	0	0.0

Output di samping menunjukkan hasil analisis terhadap keberadaan outlier pada setiap fitur (kolom) dalam dataset. Hasil analisis ini sangat baik karena menunjukkan bahwa tidak ditemukan satupun outlier pada seluruh fitur yang dianalisis. Artinya, semua nilai data pada setiap fitur berada dalam rentang yang wajar dan tidak terdapat data yang sangat jauh berbeda dari nilai-nilai lainnya (data ekstrem).

SQL Query

```
SELECT
  hotel,
  arrival_date_year,
  ROUND(AVG(is_canceled) * 100,
  2) AS cancellation_rate
FROM Dataset_Midterm_Bitlabs
dmb
GROUP BY hotel,
arrival_date_year;
```

1

Rata-rata lead-time untuk setiap kelompok jumlah permintaan khusus. Namun hanya untuk reservasi yang lead-time > rata-rata.

Output:

SELECT hotel, arrival Enter a SQL expression to filter results				
Grid		A-Z hotel	123 arrival_da	123 cancellati
	1	City Hotel	2,015	43.88
	2	City Hotel	2,016	40.4
	3	City Hotel	2,017	42.5
	4	Resort Hotel	2,015	25.72
	5	Resort Hotel	2,016	26.55
	6	Resort Hotel	2,017	30.76

SQL Query

```
SELECT
    total_of_special_requests,
    AVG(lead_time) AS
average_lead_time
FROM Dataset_Midterm_Bitlabs
dmb
WHERE lead_time > (SELECT
AVG(lead_time) FROM
Dataset_Midterm_Bitlabs dmb)
GROUP BY
total_of_special_requests;
```

2

Lead time reservasi yang diatas rata-rata untuk setiap kelompok jumlah permintaan khusus.

Output:

total_of_special_requests, AVG(lead_time) AS average_lead_time	
123 total_of_special_requests	123 average_lead_time
0	144.1587685006
0.5725533366	139.9941649058
1	135.3036969081
2	135.490601857
2.5	136.5593560433


SQL Query

```
SELECT
    reservation_status_date,
    ROUND(SUM(adr), 2) AS
total_revenue
FROM Dataset_Midterm_Bitlabs dmb
WHERE reservation_status =
'Check-Out' AND
total_of_special_requests > 2
GROUP BY reservation_status_date
ORDER BY total_revenue DESC
LIMIT 1;
```

3

Tanggal reservasi dengan pendapatan tertinggi berdasarkan rata rata adr.

Output:



	A-Z reservation_status_date	123 total_revenue
1	2016-08-18	7,013.98

SQL Query

4

```
WITH lead_time_groups AS (  
  SELECT  
    CASE  
      WHEN lead_time BETWEEN 0 AND 7 THEN '0-7 days'  
      WHEN lead_time BETWEEN 8 AND 14 THEN '8-14 days'  
      WHEN lead_time BETWEEN 15 AND 30 THEN '15-30 days'  
      WHEN lead_time BETWEEN 31 AND 60 THEN '31-60 days'  
      WHEN lead_time BETWEEN 61 AND 90 THEN '61-90 days'  
      WHEN lead_time BETWEEN 91 AND 180 THEN '91-180 days'  
      ELSE '181+ days'  
    END AS lead_time_range,  
    adr  
  FROM Dataset_Midterm_Bitlabs dmb  
)
```

Analisis hubungan antara lead time dengan average daily rate menggunakan CTE.

```
SELECT  
  lead_time_range,  
  AVG(adr) AS average_adr  
FROM  
  lead_time_groups  
GROUP BY  
  lead_time_range  
ORDER BY  
  lead_time_range;
```


SQL Query

Analisis hubungan antara lead time dengan average daily rate menggunakan CTE.

A-Z lead_time_range ▼	123 average_adr ▼
0-7 days	92.5824289945
15-30 days	102.3347234138
181+ days	94.4297014099
31-60 days	101.1626592532
61-90 days	101.5290281918
8-14 days	100.6730824349
91-180 days	100.6026848311

Exploratory Data Analysis


Rasio Antara Lead Time dan Jumlah Hari Reservasi yang Dibatalkan



Dapat dilihat bahwa sebagian besar (99,2%) merupakan total lead time, sedangkan sisanya (0,8%) adalah jumlah pembatalan. Ini mengindikasikan bahwa proporsi pembatalan relatif kecil dibandingkan dengan total keseluruhan lead time.

Exploratory Data Analysis


Perbedaan Pola Pendapatan Antara Resort Hotel dan City Hotel



Terlihat bahwa pendapatan hotel kota cenderung lebih tinggi dibandingkan dengan resor hotel sepanjang tahun. Puncak pendapatan untuk kedua jenis hotel umumnya terjadi pada bulan-bulan tertentu, diikuti oleh penurunan yang cukup tajam. Perbedaan yang mencolok antara kedua jenis hotel ini mengindikasikan adanya faktor-faktor musiman.

Exploratory Data Analysis


Asal Turis yang Sering Melakukan Cancelling Reservation



Ini adalah pie chart yang menampilkan persentase jumlah turis di 10 negara teratas yang sering melakukan pembatalan reservasi. Di urutan pertama terdapat negara Portugal (PRT), di susul oleh Great Britain (GBR) dan Spanyol (ESP).

Exploratory Data Analysis

Perilaku Pemesanan Last-Minute



Last-minute didefinisikan sebagai pemesanan dengan lead time yang kurang dari atau sama dengan 3 hari. Bar chart ini memperlihatkan perbandingan antara pemesanan last-minute dan non-last-minute, memberikan gambaran umum tentang seberapa sering tamu memesan kamar secara mendadak dibandingkan dengan pemesanan yang direncanakan lebih awal.

A/B Testing



T-statistik: 59.88445271863561

Nilai P (P-value): 0.0

Terima hipotesis satu (H1), ADR berbeda antara City Hotel dan Resort Hotel.

Uji A/B testing yang dilakukan untuk membandingkan rata-rata harga harian (ADR) antara City Hotel dan Resort Hotel, mengindikasikan bahwa terdapat perbedaan yang sangat signifikan antara kedua jenis hotel tersebut. Nilai t-statistik yang sangat tinggi (59.88) dan nilai p-value yang sangat kecil (hampir 0) menunjukkan bahwa kita dapat menolak hipotesis nol (H_0) yang menyatakan bahwa tidak ada perbedaan antara ADR kedua jenis hotel. Dengan demikian, kita menerima hipotesis alternatif (H_1) yang menyatakan bahwa rata-rata ADR antara City Hotel dan Resort Hotel berbeda secara signifikan.

Conclusion



Hotel perlu lebih adaptif dalam menyesuaikan kebijakan dengan perilaku tamu yang berbeda-beda, baik dalam hal lead time maupun permintaan khusus. Dengan mengelola permintaan tamu secara lebih baik dan memberikan fleksibilitas lebih besar pada tamu dengan lead time yang panjang, tingkat kepuasan pelanggan dapat ditingkatkan, yang pada akhirnya akan berdampak positif pada penurunan tingkat pembatalan.





Thank you

